

Previsão do Consumo de Energia no Sul do Brasil

Gabriel Campregher

28/02/2023

Abstract

O objetivo deste projeto é utilizar a metodologia Box Jenkins para estimar um modelo ARIMA, a fim de projetar o consumo residencial e industrial de energia no sul do Brasil, para o primeiro semestre de 2023. Os dados utilizados são disponibilizados pela Eletrobras e foram importados do sistema de gerenciamento de séries temporais do Banco Central.

$$\phi(L)\Delta^d Y_t = \theta(L)\epsilon_t \quad (1)$$

1. Pacotes

```
# 1.1 Carregando pacotes
library(magrittr)
library(lubridate)
library(dplyr)
library(rbcbr)
library(tsibble)
library(tidy)
library(ggplot2)
library(forecast)
library(tsDyn)
library(tseries)
library(urca)
```

2. Download e Leitura dos Dados

```
# 2.1 Importando Consumo de Energia Residencial
energia_sul_residencial = rbcbr::get_series(code = 1418,
                                             start_date = "2015-01-01",
                                             end_date = Sys.Date()) %>%
  dplyr::select("data" = "date",
               "energia" = "1418") %>%
  dplyr::as_tibble()

# 2.2 Importando Consumo de Energia Industrial
energia_sul_industrial = rbcbr::get_series(code = 1419,
                                             start_date = "2015-01-01",
                                             end_date = Sys.Date()) %>%
  dplyr::select("data" = "date",
               "energia" = "1419") %>%
```

```
dplyr::as_tibble()

# 2.3 Transformando Dados em Séries Temporais - Residencial
energia_sul_residencial_ts = ts(energia_sul_residencial$energia,
                                start = c(2015,1),
                                end = c(2022,11),
                                frequency = 12)


# 2.4 Transformando Dados em Séries Temporais - Industrial
energia_sul_industrial_ts = ts(energia_sul_industrial$energia,
                                start = c(2015,1),
                                end = c(2022,11),
                                frequency = 12)
```

3. Visualização dos Dados

Inspecionando visualmente os dados, é razoável dizer que ambas as séries em nível sofrem uma forte ação da sazonalidade e possuem uma tendência temporal ascendente. Na primeira diferença, as séries parecem ser estacionárias.


```
# 3.1 Plotando Séries em nível
par(mfrow = c(1,1))
par(cex.main = 0.75)

# 3.1.1 Plotando Série Consumo Residencial
plot(energia_sul_residencial, type = "l", main = "Consumo Residencial de Energia
na Região Sul", xlab = "anos", ylab = "GWh", col = "darkblue")
grid(nx = NULL, ny = NULL, lty = 2, col = "gray", lwd = 0.5)
```



```
# 3.1.2 Plotando Série Consumo Industrial
plot(energia_sul_industrial, type = "l",
     main = "Consumo Industrial de Energia na Região Sul",
     xlab = "anos", ylab = "GWh", col = "darkgreen")
grid(nx = NULL, ny = NULL, lty = 2, col = "gray", lwd = 0.5)
```

Consumo Industrial de Energia na Região Sul



```
# 3.2 Plotando das Séries em Diferença
```

```
par(mfrow = c(1,2))
```

```
par(cex.main = 0.75)
```

```
# 3.2.1 Plotando Série em diferença - Residencial
```

```
diff(energia_sul_residencial_ts) %>%
```

```
plot(type = "l", main = "Primeira Diferença do Consumo Residencial",  
      xlab = "anos", ylab = "GWh", col = "darkblue")
```

```
grid(nx = NULL, ny = NULL, lty = 2, col = "gray", lwd = 0.5)
```


```
# 3.2.2 Plotando Série em diferença - Industrial
```

```
diff(energia_sul_industrial_ts) %>%
```

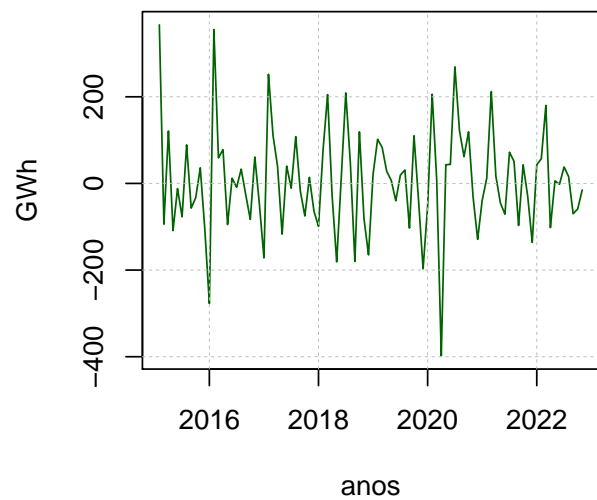
```
plot(type = "l", main = "Primeira Diferença do Consumoo Industrial",  
      xlab = "anos", ylab = "GWh", col = "darkgreen")
```

```
grid(nx = NULL, ny = NULL, lty = 2, col = "gray", lwd = 0.5)
```

Primeira Diferença do Consumo Residencial



Primeira Diferença do Consumoo Industrial



4. Modelagem

Foi utilizado o auto ARIMA para selecionar de forma automática as ordens dos parâmetros (p,d,q) do modelo. O Auto ARIMA considera automaticamente vários modelos ARIMA com diferentes combinações de parâmetros de acordo com os critérios estatísticos de AIC (Critério de Informação Akaike) ou o BIC (Critério de Informação Bayesiano).

Inspecionando visualmente os resíduos, eles parecem ser estacionários, distribuídos normalmente e não correlacionados.

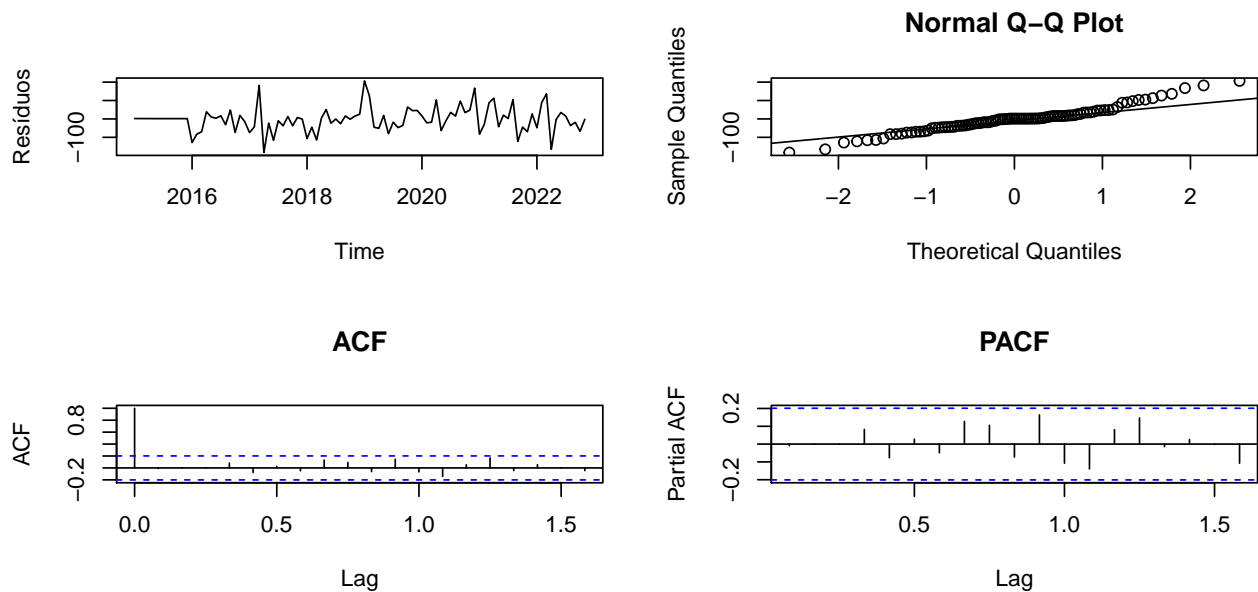
4.1 Estimando Auto ARIMA

```
modelo_residencial = forecast::auto.arima(energia_sul_residencial_ts)
modelo_industrial = forecast::auto.arima(energia_sul_industrial_ts)
```

4.2 Diagnóstico dos Resíduos

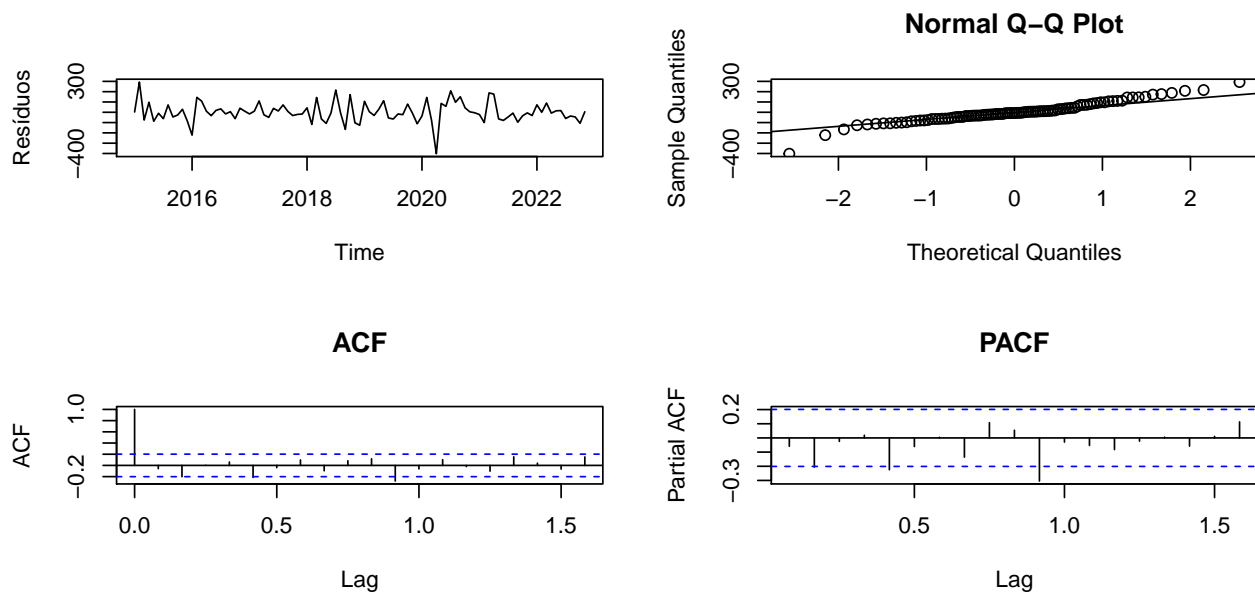
4.2.1 Resíduos ARIMA Consumo Residencial

```
par(mfrow = c(2,2))
plot(modelo_residencial$residuals, type = "l", ylab = "Resíduos")
qqnorm(modelo_residencial$residuals)
qqline(modelo_residencial$residuals)
acf(modelo_residencial$residuals, main = "ACF")
pacf(modelo_residencial$residuals, main = "PACF")
```



4.2.2 Resíduos ARIMA Consumo Residencial

```
par(mfrow = c(2,2))
plot(modelo_industrial$residuals, type = "l", ylab = "Resíduos")
qqnorm(modelo_industrial$residuals)
qqline(modelo_industrial$residuals)
acf(modelo_industrial$residuals, main = "ACF")
pacf(modelo_industrial$residuals, main = "PACF")
```



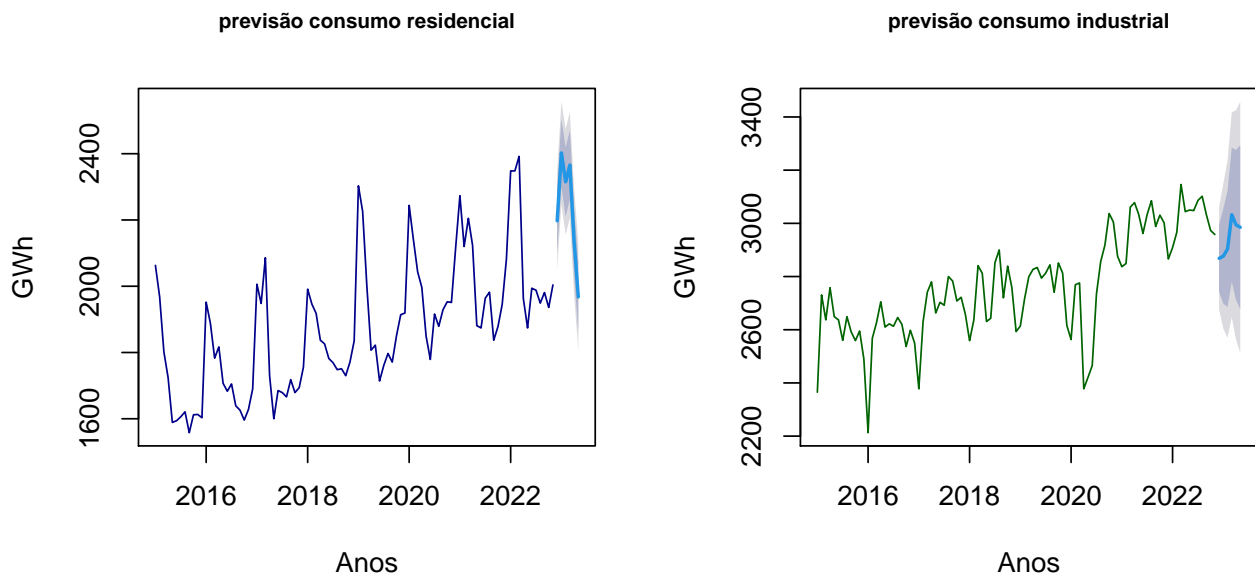
5. Previsão

5.1 Previsão

```
pred_residencial = forecast(modelo_residencial, h = 6)
pred_industrial = forecast(modelo_industrial, h = 6)
```

5.2 Plot da Previsão

```
par(cex.main = 0.75)
par(mfrow = c(1,2))
plot(pred_residencial, main = "previsão consumo residencial", col = "darkblue",
     xlab = "Anos", ylab = "GWh")
plot(pred_industrial, main = "previsão consumo industrial", col = "darkgreen",
     xlab = "Anos", ylab = "GWh")
```



6. Como Melhorar o Modelo?

O modelo ARIMA é univariado e utiliza a própria variável de interesse como variável explicativa. Uma alternativa para realizar a previsão seria adotar um modelo multivariado, utilizando, por exemplo, taxa de juros e índices de atividade econômica como variáveis independentes para explicar o consumo de energia.